LAPORAN EVALUASI TENGAH SEMESTER

MATA KULIAH BIG DATA

CLOUD-BASED RISK MANAGEMENT: FORECASTING SAHAM ENERGI (MEDC) MERESPONS ANOMALI GEOPOLITIK VIA PIPELINE AWS

DISUSUN OLEH KELOMPOK IV:

Muhammad Handika Maulana Sifa (24083010036)

Salwa Zahra Rahmawati (24083010083)

Nerissabila Uswatun Istiqomah (24083010100)

DOSEN PENGAMPU:

Masti Fatchiyah Maharani, S.Kom., M.Cs

Dr. Eng. Ir. Dwi Arman Prasetya, ST., MT., IPU., Asean. Eng

PROGRAM STUDI SAINS DATA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR

2026

DAFTAR ISI

DAFTAR ISI i
DAFTAR GAMBAR ii
DAFTAR TABEL iii
BAB I PENDAHULUAN 1
1.1. Latar Belakang 1
1.2. Rumusan Masalah 2
1.3. Tujuan Penelitian 3
BAB II KAJIAN TEORI 4
2.1 Cloud Computing 4
2.2 Amazon Web Services (AWS) 5
2.3 Saham MEDC 5
2.4 Forecasting 6
2.5 Long Short-Term Memory (LSTM) 6
BAB III HASIL DAN PEMBAHASAN 7
3.1 Arsitektur Data Pipeline 7
3.1.1 Alur Tahapan Penelitian 8
3.1.2 Layanan AWS 9
3.1.3 Koneksi Antar Komponen 10
3.14 IAM untuk Keamanan Prinsip 10
3.2 Data Source dan Collecting 10
3.2.1 Sumber Dataset (Data Source) 11
3.2.2 Deskripsi Dataset 11
3.2.3 Proses Loading Dataset (Ekstraksi) 12
3.2.4 Data Cleaning 12
3.2.5 Inspeksi Analitik dan Local Staging Area 13
3.3 Data Storage dengan AWS S3 14
3.3.1 Pembuatan S3 Bucket dan Konfigurasi Naming Convention 14
3.3.2 Arsitektur Folder (Data Lake Zone Separation) 15
3.3.3 Upload Dataset ke Folder /raw (Data Ingestion) 16
3.3.4 Aktivasi Versioning untuk Reproduktibilitas (Data Provenance & Protection) 17
3.3.5 Penyimpanan Hasil Proses ke Folder /processed (Data Consumption) 19
3.4 Data Processing dengan SageMaker 20
3.4.1 Orkestrasi Lingkungan dan Hak Akses (IAM Role) 20
3.4.2 Ingestion Data Mentah dari AWS S3 (Cloud to Memory) 21
3.4.3 Data Cleansing dan Normalisasi Struktur 22
3.4.4 Feature Engineering dan Analisis Statistika 23
3.4.5 Data Serialization dan Write-Back ke AWS S3 24
3.5. Data Accessing dan Visualization 25

3.5.1 Analisis Pergerakan Harga Saham MEDC.....25
3.5.2 Overlay Peristiwa Geopolitik terhadap Harga Saham.....27
3.5.3 Perbandingan Harga Aktual dan Prediksi (LSTM)..... 28
3.5.4 Forecasting Harga Saham MEDC..... 29
BAB IV KESIMPULAN..... 31
BAB V KONTRIBUSI ANGGOTA KELOMPOK.....33
DAFTAR PUSTAKA.....35
LAMPIRAN.....37

DAFTAR GAMBAR

Gambar 3.1 Arsitektur Data Pipeline Forecasting Saham MEDC..... 7
Gambar 3.2 Code Handling Missing Values..... 12
Gambar 3.3 Code Restrukturisasi Indeks..... 13
Gambar 3.4 Code Reduksi Dimensi..... 13
Gambar 3.5 Code Exploratory Data Analysis..... 13
Gambar 3.6 Code Local Staging Area.....13
Gambar 3.7 Create Bucket AWS S3.....15
Gambar 3.8 Struktur Bucket.....16
Gambar 3.9 Upload Dataset ke Folder /raw..... 17
Gambar 3.10 Aktivasi Versioning..... 18
Gambar 3.11 Code Konfigurasi Versioning..... 18
Gambar 3.12 Penyimpanan Hasil Proses ke Folder /processed..... 20
Gambar 3.13 Orkestrasi Lingkungan dan Hak Akses (IAM Role)..... 21
Gambar 3.14 Code Ingestion Data Mentah..... 22
Gambar 3.15 Code Bypassing Anomaly..... 22
Gambar 3.16 Code Feature Selection & Renaming..... 23
Gambar 3.17 Code Standardisasi Tipe Data.....23
Gambar 3.18 Code Sanitasi Observasi..... 23
Gambar 3.19 Code Momentum dan Risiko Historis..... 24
Gambar 3.20 Code Deteksi Tren..... 24
Gambar 3.21 Code Deteksi Anomali Geopolitik..... 24
Gambar 3.22 Code Data Serialization dan Write-Back ke AWS S3..... 25
Gambar 3.23 Visualisasi Analisis Pergerakan Harga Saham MEDC.....26
Gambar 3.24 Visualisasi Overlay Geopolitik.....27
Gambar 3.25 Visualisasi Perbandingan Harga Aktual vs Prediksi LSTM.....28
Gambar 3.26 Visualisasi Forecasting Harga Saham MEDC.....29

DAFTAR TABEL

Tabel 3.1 Variabel Penelitian..... 11

BAB I
PENDAHULUAN

1.1. Latar Belakang

Perkembangan dinamika geopolitik global dalam lima tahun terakhir menunjukkan peningkatan ketidakstabilan yang signifikan dan berdampak langsung terhadap sektor energi dunia. Sejak tahun 2020, pasar energi global mengalami tekanan yang signifikan akibat berbagai peristiwa besar yang terjadi secara berturut-turut. Pandemi COVID-19 yang mulai menyebar pada tahun 2020 menyebabkan gangguan pada rantai pasok global serta penurunan aktivitas ekonomi secara drastis, yang berdampak langsung terhadap permintaan dan harga minyak dunia (Siregar dkk., 2022). Selanjutnya, konflik Russia-Ukraina War yang terjadi pada tahun 2022 memicu krisis energi terutama di kawasan Eropa akibat terganggunya pasokan energi dari Rusia. Kondisi ini menyebabkan lonjakan harga minyak dan gas serta meningkatkan volatilitas pasar energi global (Wicaksana dkk., 2022). Selain itu, eskalasi konflik di kawasan Timur Tengah, termasuk ketegangan antara Iran dengan United States dan Israel, turut memberikan tekanan tambahan terhadap stabilitas pasar minyak dunia. Ketidakpastian geopolitik di kawasan tersebut seringkali memicu fluktuasi harga energi karena kekhawatiran terhadap gangguan pasokan global (Mawarda dkk., 2025). Konflik di Timur Tengah ini menyebabkan krisis di Selat Hormuz sebagai jalur distribusi utama minyak global juga terus menjadi perhatian strategis karena risiko gangguan pasokan yang dapat terjadi sewaktu-waktu (Ramadhani dan Marzaman, 2024). Rangkaian peristiwa ini menunjukkan bahwa faktor geopolitik memiliki pengaruh kuat terhadap stabilitas harga energi global. Kondisi tersebut menciptakan anomali pasar yang ditandai dengan lonjakan harga yang tidak wajar serta peningkatan volatilitas yang tinggi.

Dampak dari berbagai peristiwa geopolitik tersebut secara langsung tercermin pada fluktuasi harga minyak mentah global, yang kemudian memengaruhi kinerja perusahaan energi, termasuk emiten migas di Indonesia seperti Medco Energi Internasional (MEDC). Sebagai perusahaan yang bergerak di sektor energi, saham MEDC memiliki sensitivitas tinggi terhadap perubahan harga minyak dunia. Dalam periode lima tahun terakhir, pergerakan saham MEDC menunjukkan pola yang dinamis dengan adanya lonjakan tajam pada periode tertentu, terutama saat terjadi krisis global seperti perang Rusia–Ukraina dan peningkatan ketegangan di Timur Tengah (Septiana,

2022). Fluktuasi ini tidak hanya mencerminkan kondisi fundamental perusahaan, tetapi juga respons pasar terhadap faktor eksternal yang bersifat tidak pasti. Kondisi tersebut menimbulkan risiko yang cukup tinggi bagi investor dalam menentukan strategi investasi (Hisam, 2024).

Dalam konteks analisis data, penggunaan pendekatan *time-series forecasting* menjadi sangat relevan untuk mengidentifikasi pola pergerakan harga saham yang dipengaruhi oleh berbagai peristiwa global. Data historis dalam lima tahun terakhir menunjukkan adanya karakteristik data yang kompleks, seperti tren yang berubah secara dinamis, lonjakan (*spikes*), serta kemunculan outlier yang signifikan akibat *shock* geopolitik. Untuk mengelola dan menganalisis data dengan karakteristik tersebut, dibutuhkan teknologi yang mampu menangani data dalam skala besar secara efisien. Cloud computing hadir sebagai solusi dengan menyediakan infrastruktur yang fleksibel dan skalabel untuk pengolahan data. Layanan seperti Amazon Web Services (AWS) memungkinkan integrasi pipeline data secara end-to-end, mulai dari proses pengumpulan data, penyimpanan, pemrosesan, hingga analisis dan visualisasi (Patel, 2025). Dengan demikian, proses analisis dapat dilakukan secara lebih sistematis dan terintegrasi.

Urgensi penelitian ini terletak pada kebutuhan akan sistem manajemen risiko yang mampu merespons dinamika pasar secara cepat dan akurat, khususnya dalam menghadapi ketidakpastian geopolitik global. Konflik Iran vs Amerika Serikat dan Israel yang kembali memanas dalam beberapa waktu terakhir, serta potensi gangguan di Selat Hormuz, menjadi indikator bahwa risiko geopolitik terhadap sektor energi masih sangat tinggi. Dengan memanfaatkan model *forecasting* yang terintegrasi dalam pipeline berbasis cloud, investor dapat memperoleh insight yang lebih baik dalam memprediksi pergerakan harga saham energi, khususnya MEDC. Selain itu, visualisasi data dalam dapat membantu dalam mengidentifikasi tren, distribusi, dan anomali data secara lebih intuitif. Oleh karena itu, pengembangan sistem *cloud-based risk management* berbasis AWS menjadi solusi strategis dalam mendukung pengambilan keputusan investasi yang adaptif, berbasis data, dan responsif terhadap perubahan kondisi global.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana pengaruh peristiwa geopolitik global dalam lima tahun terakhir, seperti pandemi COVID-19, konflik Rusia-Ukraina, serta konflik Iran vs AS-Israel, terhadap pergerakan dan volatilitas saham energi, khususnya MEDC?
2. Bagaimana karakteristik pola data time-series saham MEDC dalam merespons berbagai *shock* geopolitik, terutama dalam bentuk tren, lonjakan (*spikes*), dan outlier?
3. Bagaimana merancang dan mengimplementasikan pipeline data berbasis AWS serta model *forecasting* untuk mendukung analisis dan manajemen risiko pada saham energi?

1.3. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah disusun, maka tujuan dari penelitian ini adalah untuk:

1. Menganalisis dampak peristiwa geopolitik global dalam lima tahun terakhir terhadap pergerakan dan volatilitas saham MEDC.
2. Mengidentifikasi dan memahami pola data time-series saham MEDC yang dipengaruhi oleh faktor eksternal seperti krisis geopolitik.
3. Membangun pipeline analitik berbasis AWS serta mengembangkan model *forecasting* untuk mendukung manajemen risiko dan pengambilan keputusan investasi.

BAB II
KAJIAN TEORI

2.1 *Cloud Computing*

Cloud computing merupakan model komputasi yang memungkinkan pengguna untuk mengakses berbagai sumber daya teknologi informasi seperti server, penyimpanan, jaringan, dan aplikasi melalui internet secara fleksibel. Menurut National Institute of Standards and Technology, *cloud computing* adalah model yang memungkinkan akses jaringan yang luas terhadap sumber daya komputasi yang dapat dikonfigurasi dan disediakan dengan cepat serta dapat dilepaskan dengan upaya manajemen yang minimal (Younus dkk., 2025). Konsep ini memungkinkan organisasi untuk tidak lagi bergantung pada infrastruktur fisik yang mahal dan kompleks. Selain itu, cloud computing juga memberikan kemudahan dalam pengelolaan sistem karena sebagian besar proses dilakukan secara otomatis oleh penyedia layanan. Dengan demikian, teknologi ini menjadi solusi yang efisien dan fleksibel dalam mendukung kebutuhan komputasi modern.

Cloud computing memiliki beberapa karakteristik utama yang membedakannya dari sistem komputasi tradisional. Karakteristik tersebut meliputi *on-demand self-service*, yaitu pengguna dapat mengakses layanan secara mandiri tanpa interaksi langsung dengan penyedia layanan. Selain itu, terdapat *broad network access* yang memungkinkan layanan diakses melalui berbagai perangkat yang terhubung dengan jaringan. *Resource pooling* memungkinkan sumber daya komputasi digunakan secara bersama-sama oleh banyak pengguna dengan sistem *multi-tenant*. *Rapid elasticity* memberikan kemampuan untuk menyesuaikan kapasitas sumber daya secara cepat sesuai kebutuhan. Terakhir, *measured service* memungkinkan penggunaan sumber daya dipantau dan dihitung sehingga pengguna hanya membayar sesuai pemakaian (Duha dkk., 2022)

Selain karakteristik, cloud computing juga memiliki model layanan yang terbagi menjadi tiga jenis utama, yaitu *Infrastructure as a Service* (IaaS), *Platform as a Service* (PaaS), dan *Software as a Service* (SaaS). IaaS menyediakan infrastruktur dasar seperti server virtual dan penyimpanan yang dapat dikontrol oleh pengguna secara penuh. PaaS menyediakan platform yang memungkinkan pengguna untuk mengembangkan dan menjalankan aplikasi tanpa harus mengelola infrastruktur secara langsung. Sedangkan SaaS menyediakan aplikasi yang dapat digunakan secara langsung melalui internet tanpa

perlu instalasi atau pengelolaan sistem. Ketiga model ini memberikan tingkat fleksibilitas dan kontrol yang berbeda sesuai dengan kebutuhan pengguna (Younis, 2024).

2.2 Amazon Web Services (AWS)

Amazon Web Services (AWS) merupakan salah satu platform cloud computing yang menyediakan berbagai layanan untuk kebutuhan komputasi, penyimpanan, jaringan, serta analisis data secara terintegrasi. AWS menawarkan berbagai layanan utama seperti Amazon S3 untuk penyimpanan data, Amazon EC2 untuk komputasi berbasis virtual server, serta Amazon SageMaker untuk pengembangan dan deployment model *machine learning* (Saini dkk., 2024). Platform ini dirancang untuk mendukung berbagai kebutuhan pengguna, mulai dari individu hingga perusahaan berskala besar, dengan tingkat fleksibilitas yang tinggi. Selain itu, AWS juga memungkinkan pengguna untuk mengakses sumber daya komputasi secara on-demand tanpa perlu membangun infrastruktur fisik sendiri. Hal ini menjadikan AWS sebagai solusi yang efisien dalam pengelolaan sistem berbasis teknologi informasi modern.

Keunggulan utama AWS terletak pada skalabilitas, fleksibilitas, serta kemampuannya dalam mengintegrasikan berbagai layanan dalam satu ekosistem yang terpadu. AWS memungkinkan pengguna untuk menyesuaikan kapasitas sumber daya sesuai kebutuhan, sehingga dapat mengoptimalkan biaya operasional. Selain itu, AWS juga menyediakan sistem keamanan yang kuat, termasuk enkripsi data dan manajemen akses berbasis identitas. Dukungan terhadap berbagai tools dan framework analitik seperti TensorFlow dan PyTorch juga menjadikan AWS sangat relevan dalam pengembangan aplikasi berbasis data dan *machine learning*. Dengan fitur-fitur tersebut, AWS banyak digunakan dalam berbagai bidang, termasuk pengolahan big data, pengembangan aplikasi, serta analisis prediktif (Iskandar dkk., 2021).

2.3 Saham MEDC

Saham merupakan salah satu instrumen investasi yang menunjukkan kepemilikan seseorang atau badan terhadap suatu perusahaan. Kepemilikan saham memberikan hak kepada investor untuk memperoleh bagian keuntungan perusahaan dalam bentuk dividen serta potensi keuntungan dari selisih harga jual dan beli saham (*capital gain*). Pergerakan harga saham di pasar bersifat fluktuatif dan dipengaruhi oleh berbagai faktor, baik internal

maupun eksternal. Faktor internal meliputi kinerja keuangan perusahaan, strategi bisnis, serta efektivitas manajemen dalam menjalankan operasional perusahaan. Sementara itu, faktor eksternal mencakup kondisi ekonomi makro, tingkat suku bunga, inflasi, serta dinamika pasar global yang dapat memengaruhi sentimen investor (Sari dan Riwayati, 2024).

2.4 *Forecasting*

Forecasting merupakan proses peramalan nilai di masa depan berdasarkan data historis dengan menggunakan metode tertentu, baik statistik maupun berbasis *machine learning*. Dalam konteks pasar saham, *forecasting* digunakan untuk memprediksi harga saham di masa mendatang sehingga dapat membantu investor dalam mengambil keputusan investasi yang lebih tepat. Metode forecasting tradisional seperti regresi dan ARIMA telah banyak digunakan, namun memiliki keterbatasan dalam menangkap pola non-linear yang kompleks. Seiring perkembangan teknologi, metode berbasis *machine learning* dan *deep learning* mulai banyak digunakan karena kemampuannya dalam mengolah data dalam jumlah besar dan menemukan pola tersembunyi (Hassani & Silva, 2021).

2.5 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) merupakan salah satu metode dalam *deep learning* yang digunakan untuk memproses data sekuensial, seperti data *time-series*. LSTM merupakan pengembangan dari *Recurrent Neural Network* (RNN) yang dirancang untuk mengatasi permasalahan *vanishing gradient*. Model ini memiliki kemampuan untuk mengingat informasi dalam jangka waktu yang panjang melalui mekanisme *memory cell* dan *gate*. Dengan kemampuan tersebut, LSTM dapat menangkap pola kompleks yang tidak dapat diidentifikasi oleh metode tradisional (Okut, 2021). Hal ini menjadikan LSTM sebagai salah satu metode yang banyak digunakan dalam analisis data berbasis waktu.

BAB III

HASIL DAN PEMBAHASAN

3.1 Arsitektur Data Pipeline

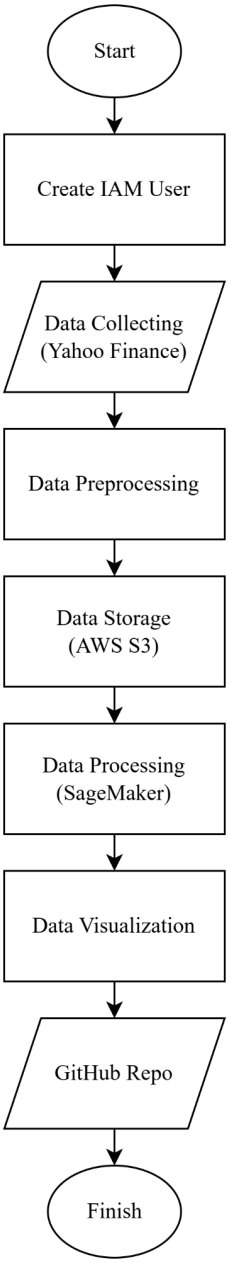

Gambar 3.1 Arsitektur Data Pipeline Forecasting Saham MEDC

Berdasarkan Gambar 3.1, arsitektur *end-to-end data pipeline* dibangun menggunakan pendekatan komputasi awan berbasis Amazon Web Services (AWS) untuk menjamin skalabilitas dan efisiensi pemrosesan data runtun waktu (*time-series*).

3.1.1 Alur Tahapan Penelitian

Alur pemrosesan data (*data flow*) berjalan secara sekuensial dengan tahapan sebagai berikut:

1. Data Collecting (Pengumpulan Data via API)

   Ekstraksi data historis pergerakan harga saham PT Medco Energi Internasional Tbk (Ticker: MEDC.JK) dilakukan secara terprogram (*programmatic*) memanfaatkan antarmuka API publik dari layanan Yahoo Finance. Penarikan data dikonfigurasi secara spesifik dengan rentang waktu (*time window*) 5 tahun terakhir untuk menangkap seluruh siklus makroekonomi dan anomali geopolitik yang memengaruhi fluktuasi rantai pasok energi global. Atribut tabular yang ditarik mencakup nilai fundamental perdagangan bursa seperti harga pembukaan (*Open*), nilai tertinggi/terendah harian (*High/Low*), harga penutupan (*Close*), hingga volume transaksi institusional (*Volume*).

2. Data Preprocessing (Pra-pemrosesan Data)

   Sebelum diintegrasikan ke dalam infrastruktur *cloud*, data mentah menjalani tahapan pra-pemrosesan awal menggunakan modul *library* Pandas pada bahasa pemrograman Python. Proses ini berfokus pada standardisasi kualitas data (*data quality control*), yang mencakup inspeksi dan eliminasi baris data kosong atau terkorupsi (*handling missing values/NaN*) menggunakan fungsi eliminasi baris, serta penyesuaian tipe data (*data type formatting*) dengan mereset indeks tanggal (*Date*) menjadi kolom operasional mandiri. Pembersihan tahap awal ini sangat krusial untuk mencegah fenomena komputasi *garbage-in, garbage-out* pada saat pemodelan regresi di *pipeline* selanjutnya.

3. Data Storage - Raw (Penyimpanan Data Mentah)

   Data terstruktur yang telah melewati tahap pembersihan awal diunggah (*ingestion*) ke dalam layanan penyimpanan objek terpusat Amazon S3. Sesuai dengan arsitektur yang dibangun, berkas CSV tersebut dialokasikan secara spesifik ke dalam direktori /raw di dalam *bucket* utama. Proses transfer data ini dieksekusi secara *in-memory* menggunakan perantara antarmuka Boto3 (AWS SDK for Python) dan modul *buffer string*, sehingga memastikan efisiensi tanpa membebani penyimpanan lokal. Selain itu, fitur *Versioning* pada S3 diaktifkan secara mandiri sebagai bentuk tata kelola data (*data governance*) untuk mencegah hilangnya

berkas historis selama fase uji coba sistem.

4. Data Processing (Pemrosesan Komputasi & Pemodelan)

   Tahapan komputasi analitik dan pemodelan prediktif didistribusikan secara terpusat di dalam *environment* komputasi AWS SageMaker (atau EC2). Layanan komputasi awan ini melakukan interaksi *read data* dengan menarik data langsung dari direktori S3 /raw menuju memori *virtual machine*. Pada tahap ini, *pipeline* algoritma pemodelan prediksi (*forecasting*) berbasis *Machine Learning* dikonstruksi. Proses komputasi meliputi seleksi variabel independen, pembentukan variabel target (harga penutupan pada periode berikutnya), hingga pelatihan algoritma statistika untuk menghasilkan proyeksi pergerakan harga saham di tengah tingginya volatilitas sektor energi.

5. Data Storage - Processed (Penyimpanan Data Hasil)

   Seluruh hasil komputasi dari model *Machine Learning*, beserta nilai proyeksinya, dikonsolidasikan dan digabungkan kembali (*merge*) dengan dataset historis aslinya untuk membentuk satu kesatuan informasi yang utuh. *Dataframe* final yang memuat metrik aktual dan prediksi tersebut kemudian dikonversi ulang menjadi format CSV dan dikirim (*write*) kembali menuju infrastruktur AWS S3. Untuk menjaga isolasi arsitektur data, berkas *output* ini disimpan secara terpisah pada direktori /processed. Direktori ini secara arsitektur bertindak sebagai *Single Source of Truth* (sumber kebenaran tunggal) yang siap dikonsumsi oleh aplikasi di sisi *frontend*.

6. Data Visualization (Visualisasi Data & Dashboarding)

   Pada tahap akhir pipeline komputasi awan, data yang telah melalui pemrosesan model di direktori /processed diekstraksi kembali untuk dianalisis secara visual. Berbeda dengan penggunaan platform BI eksternal, proyek ini mengadopsi pendekatan *In-Notebook Visualization* menggunakan library Matplotlib. Pemilihan Matplotlib didasarkan pada kebutuhan akan kontrol penuh terhadap parameter statistik dan kemampuan reproduktibilitas tinggi yang terintegrasi langsung dengan skrip pemrosesan tanpa memerlukan konektor pihak ketiga.

3.1.2 Layanan AWS

Untuk mengimplementasikan arsitektur *pipeline* komputasi awan ini, layanan AWS

yang dieksekusi secara spesifik meliputi:

1. AWS IAM (*Identity and Access Management*)

   Digunakan sebagai lapis kontrol keamanan untuk mendefinisikan otorisasi akses (*role* dan *policies*) secara terpusat tanpa menggunakan kredensial *root account*.

2. Amazon S3 (*Simple Storage Service*)

   Berfungsi sebagai *Data Lake* utama proyek. Layanan ini menyimpan objek dataset tabular secara terstruktur dengan fitur *versioning* yang diaktifkan untuk mencegah kehilangan data selama iterasi eksperimen.

3. Amazon SageMaker

   Digunakan sebagai platform komputasi utama (alternatif dari EC2) untuk mengeksekusi *Jupyter Notebook* secara terkelola penuh (*fully managed*), memungkinkan pemrosesan analitik dan *training* model dijalankan langsung di infrastruktur *cloud* tanpa membebani memori lokal.

3.1.3 Koneksi Antar Komponen

Integrasi antar komponen dalam *pipeline* ini dihubungkan secara terprogram (*programmatic access*). Titik koneksi krusial berada pada penggunaan SDK Boto3 di dalam *script* Python. Boto3 bertindak sebagai jembatan komunikasi (*client*) yang memungkinkan *environment* eksekusi (seperti AWS SageMaker atau mesin lokal saat *preprocessing*) untuk melakukan operasi *read/write* (mengambil data mentah dan menyimpan data hasil) langsung ke *bucket* Amazon S3 melalui jaringan API AWS.

3.14 IAM untuk Keamanan Prinsip

Least Privilege diterapkan secara ketat melalui layanan AWS IAM. Otentikasi dan otorisasi *pipeline* tidak menggunakan kredensial tingkat *root*, melainkan diisolasi pada IAM User dan IAM Role khusus. IAM Role ini hanya dibekali *permission* spesifik, yaitu AmazonS3FullAccess untuk membaca dan memanipulasi objek di dalam *bucket* penyimpan data.

3.2 Data Source dan Collecting

Tahap pengumpulan dan pra-pemrosesan data merupakan fondasi krusial dalam siklus hidup *Machine Learning*, yang sering disebut sebagai fase *Extract, Transform, Load* (ETL). Sesuai dengan batasan arsitektur komputasi awan yang dirancang, fase awal ini

dieksekusi secara terprogram menggunakan bahasa Python sebelum data mentah didistribusikan ke dalam ekosistem AWS S3.

3.2.1 Sumber Dataset (Data Source)

Dataset diekstraksi secara *real-time* memanfaatkan antarmuka API Publik Yahoo Finance yang dipanggil melalui pustaka (*library*) yfinance. Pemilihan metode *API Pulling* ini sangat disarankan secara teknis dibandingkan metode *web scraping* HTML konvensional. Pendekatan API menjamin stabilitas struktur data yang ditarik, terbebas dari risiko kegagalan akibat perubahan antarmuka (*User Interface*) situs web sumber, dan secara legal diperbolehkan untuk keperluan komputasi akademik.

3.2.2 Deskripsi Dataset

Dataset yang diakuisisi merekam riwayat transaksi pasar modal untuk emiten PT Medco Energi Internasional Tbk (MEDC.JK). Karakteristik dan dimensi dataset pasca-ekstraksi adalah sebagai berikut:

1. Rentang Waktu (*Time Window*)

   Ditetapkan menggunakan parameter periode = "5y" untuk menarik data historis selama 5 tahun terakhir (2021–2026). Rentang ini secara empiris sangat ideal (*statistically significant*) untuk menangkap anomali harga akibat sentimen geopolitik dan krisis energi makro, sekaligus menghindari bias kedaluwarsa data (*concept drift*).

2. Format Penyimpanan

   Data direpresentasikan dalam format tabular dan disimpan sebagai *Comma Separated Values* (.csv) murni.

3. Fitur Utama (*Attributes*): Dataset difilter secara ketat (*feature selection*) untuk mempertahankan 6 atribut esensial, yaitu:

Tabel 3.1 Variabel Penelitian

Variabel	Tipe Data	Keterangan
Date	Date	Indeks kronologis perdagangan berformat YYYY-MM-DD.
Open	Integer	Harga ekuilibrium pembukaan sesi bursa harian.
High	Float	Rentang harga tertinggi harian yang

Variabel	Tipe Data	Keterangan
		merepresentasikan tingkat volatilitas pasar.
Low	Float	Rentang harga terendah harian yang merepresentasikan tingkat volatilitas pasar.
Close	Float	Harga penutupan resmi yang akan bertindak sebagai variabel target (label) pada model *forecasting* nanti.
Volume	Integer	Metrik likuiditas yang mengukur total kuantitas lembar saham yang berpindah tangan antar investor.

3.2.3 Proses Loading Dataset (Ekstraksi)

Proses ekstraksi (*loading*) data dari *server* Yahoo Finance ke dalam memori kerja (*RAM*) dilakukan menggunakan fungsi yf.download(). Untuk menjamin keandalan *pipeline* (*fault tolerance*), *script* dilengkapi dengan sistem pengecekan logikal (*error handling*). Sistem akan mengevaluasi kondisional if data.empty: untuk memastikan bahwa API berhasil merespons dan data terisi penuh. Jika tervalidasi, objek data secara dinamis dikonversi menjadi format struktur *Pandas DataFrame* untuk memfasilitasi pemrosesan matriks lebih lanjut.

3.2.4 Data Cleaning

Sesuai dengan prinsip *garbage-in, garbage-out* dalam *Data Science*, dataset mentah harus disanitasi sebelum dikirim ke mesin komputasi AWS. Proses *cleaning* (*Transform*) dilakukan melalui tiga operasi fundamental:

1. Penanganan Nilai Kosong (*Handling Missing Values*)

   Implementasi fungsi data.dropna() dieksekusi untuk mengeliminasi baris observasi yang mengandung nilai NaN (seperti saat hari libur nasional di mana bursa tutup namun API tetap mencatat baris waktu). Hal ini krusial untuk menjaga integritas temporal algoritma runtun waktu (*time-series*).

```
# Menghapus baris yang memiliki nilai kosong
data_clean = data.dropna()
```

Gambar 3.2 Code *Handling Missing Values*

2. Restrukturisasi Indeks (*Index Resetting*)

   Melalui fungsi data.reset_index(), atribut 'Date' yang secara *default* terkunci

sebagai indeks internal sistem Pandas, dilepaskan menjadi kolom observasi standar. Langkah ini memastikan kompatibilitas format skema kolom ketika data dibaca oleh AWS S3 dan Amazon SageMaker.

```
# Mengembalikan 'Date' dari index menjadi kolom biasa
data_clean = data_clean.reset_index()
```

Gambar 3.3 Code Restrukturisasi Indeks

3. Reduksi Dimensi (*Feature Subsetting*)

Memangkas kolom yang tidak berkontribusi langsung pada model analitik (misalnya membuang kolom Adj Close) dengan mendeklarasikan himpunan kolom_utama.

```
# Memilih kolom esensial yang umum digunakan untuk forecasting
kolom_utama = ['Date', 'Open', 'High', 'Low', 'Close', 'Volume']
data_final = data_clean[kolom_utama]
```

Gambar 3.4 Code Reduksi Dimensi

3.2.5 Inspeksi Analitik dan Local Staging Area

Sebelum data diunggah ke AWS S3, *pipeline* mengeksekusi fase *Exploratory Data Analysis* (EDA) minor menggunakan perintah info() dan describe(). Fase ini memvalidasi tidak adanya inkonsistensi tipe data (memastikan semua harga berbentuk numerik *float*). Setelah lolos inspeksi, data akhir disimpan ke penyimpanan lokal sementara (*Local Staging Area*) menjadi fail medc.csv melalui perintah to_csv(), memastikan berkas terisolasi dengan aman sebelum proses unggah *cloud* (*put object*) dilakukan di tahap selanjutnya.

```
print("\n--- Info Struktur Data ---")
print(data_final.info())

print("\n--- Ringkasan Statistik ---")
print(data_final.describe())
```

Gambar 3.5 Code *Exploratory Data Analysis*

```
nama_file = "medc.csv"
data_final.to_csv(nama_file, index=False)
print(f"\nData berhasil disimpan secara lokal dengan nama: {nama_file}")
```

Gambar 3.6 Code Local Staging Area

3.3 Data Storage dengan AWS S3

Pada arsitektur *pipeline* komputasi awan yang dirancang untuk *forecasting* pergerakan harga saham, Amazon Simple Storage Service (S3) diimplementasikan sebagai infrastruktur *Data Lake* utama. Secara analitik, pemilihan S3 mengungguli alternatif lain seperti Amazon EBS (*Elastic Block Store*) atau Amazon EFS (*Elastic File System*). S3 menggunakan arsitektur *object storage* yang secara fundamental memisahkan lapisan komputasi dan lapisan penyimpanan (*decoupling compute and storage*). Hal ini memungkinkan *pipeline Machine Learning* untuk melakukan penskalaan penyimpanan secara independen tanpa batas (skalabilitas tak terbatas), memberikan *durability* data mencapai 99,999999999% (11 *nines*), serta menekan biaya operasional secara signifikan karena kita hanya membayar kapasitas yang terpakai untuk komputasi analitik.

3.3.1 Pembuatan S3 Bucket dan Konfigurasi Naming Convention

Langkah fundamental dalam inisiasi infrastruktur penyimpanan adalah pembuatan kontainer objek atau yang direpresentasikan sebagai *bucket*. *Bucket* ini diinisialisasi dengan identitas medc-energy-forecasting. Penamaan ini tidak dilakukan secara acak, melainkan secara ketat mematuhi *naming convention* S3 yang mewajibkan keunikan secara global di seluruh akun AWS di dunia (*globally unique*), mematuhi format *DNS-compliant* (tanpa huruf kapital dan spasi), serta bersifat deskriptif agar mudah diidentifikasi dalam orkestrasi arsitektur *multi-tenant* yang lebih besar. *Bucket* dialokasikan pada klaster *Availability Zone* di dalam *Region* ap-southeast-1 (Singapura). Secara arsitektural dan bisnis, pemilihan lokasi geografis ini didasarkan pada tiga justifikasi utama:

1. Optimalisasi Latensi Jaringan (*Network Latency*)

   Meminimalkan *round-trip time* (RTT) transmisi data antara infrastruktur *cloud* AWS dan titik akses lokal (Indonesia), sehingga proses *read/write* data saat penarikan API berjalan secara instan.

2. Kepatuhan Residensi Data (Data Residency)

   Memastikan kepatuhan terhadap regulasi lokalisasi data, di mana data finansial regional disimpan dalam yurisdiksi Asia Tenggara.

3. *Cost-Efficiency*

   Mengoptimalkan pemanfaatan skema *AWS Free Tier* yang memiliki alokasi spesifik pada *region* tersebut, memastikan efisiensi anggaran (*cost-aware architecture*).

Dalam aspek tata kelola keamanan siber (*cloud security*), fitur Access Control List (ACL) dinonaktifkan sepenuhnya (*ACLs disabled*). Otorisasi akses diregulasi secara terpusat dan granular melalui IAM (Identity and Access Management) dan *Bucket Policies*. Hal ini merupakan bentuk konkret dari implementasi prinsip keamanan *Least Privilege*. Dalam praktiknya, akses *root* diblokir, dan hanya peran (IAM Role) spesifik, seperti instansi komputasi SageMaker atau skrip Boto3 yang diberikan otorisasi aksi spesifik berupa s3:PutObject untuk mengunggah dan s3:GetObject untuk membaca data.

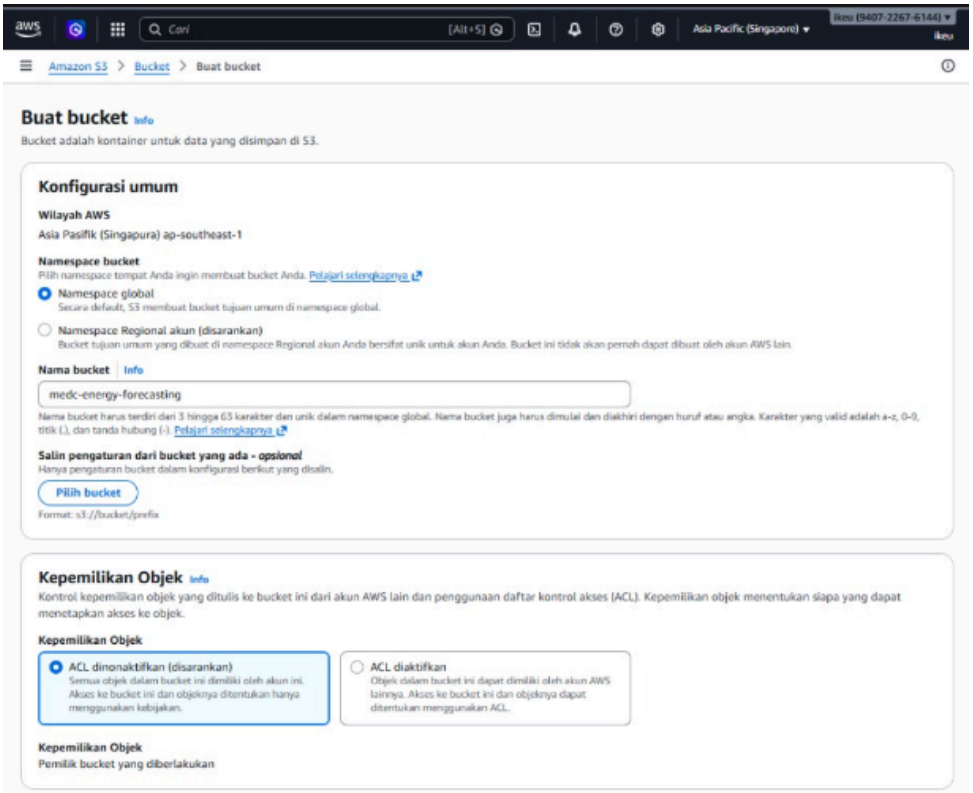

Gambar 3.7 *Create* Bucket AWS S3

3.3.2 Arsitektur Folder (*Data Lake Zone Separation*)

Untuk mencegah degradasi *Data Lake* menjadi *Data Swamp* (rawa data yang tidak terstruktur), hierarki direktori di dalam *bucket* medc-energy-forecasting dirancang menggunakan adaptasi dari kerangka kerja *Medallion Architecture* yang merepresentasikan tingkat kematangan data (*Data Maturity Levels*):

1. Direktori /raw (*Bronze Zone - Raw Data Ingestion*)

   Berfungsi sebagai *Landing Area* statis. Zona ini secara eksklusif didedikasikan untuk menyimpan dataset mentah hasil ekstraksi API (Yahoo Finance) yang belum mengalami mutasi, imputasi, atau transformasi komputasi apapun. Penyimpanan di zona ini bersifat *immutable* (tidak dapat diubah secara

sistem). Tujuan analitiknya adalah menjaga rekam jejak (*data lineage*) historis absolut. Jika sewaktu-waktu terjadi kerusakan algoritma pada *pipeline* utama, *Data Scientist* dapat melakukan re-kalkulasi dari nol menggunakan data asli ini.

2. Direktori /processed (*Silver/Gold Zone - Curated & Consumption*)

   Berfungsi sebagai zona konsumsi analitik yang telah diperkaya (*enriched*). Folder ini didedikasikan untuk menyimpan aset data yang telah matang secara statistik, mencakup dataset yang telah melewati tahapan *data cleansing*, *feature engineering*, reduksi dimensi, serta berkas keluaran (*output*) berupa tabel proyeksi prediksi (*forecasting*). Data di zona ini dipersiapkan agar memiliki skema yang *schema-on-read* kompatibel dengan instrumen visualisasi.

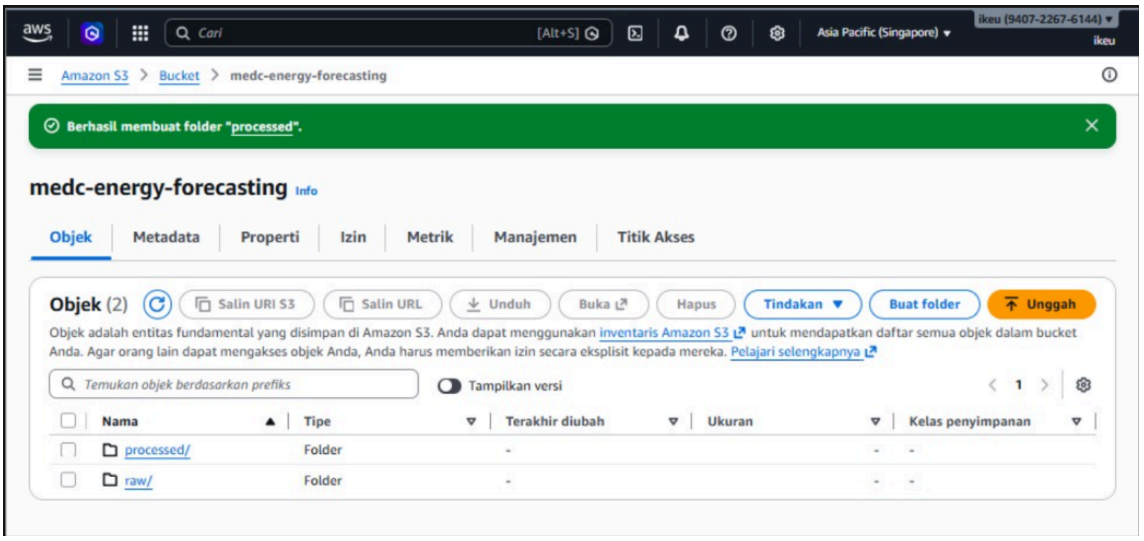

Gambar 3.8 Struktur Bucket

3.3.3 Upload Dataset ke Folder /raw (*Data Ingestion*)

Proses akuisisi dan pemindahan data (*data ingestion*) dari lingkungan komputasi (lokal/Google Colab) ke dalam *cloud* dieksekusi secara otomatis menggunakan integrasi *AWS SDK for Python* (Boto3). Pemanggilan metode s3.meta.client.upload_file memungkinkan pengiriman berkas melalui jalur TCP/IP yang aman. Dataset pergerakan saham PT Medco Energi Internasional Tbk (MEDC.JK) yang dikirim ke direktori /raw ini memiliki spesifikasi teknis dan analitik sebagai berikut:

1. Dimensi Matriks dan Periode

   Dataset memiliki dimensi presisi dengan total 1.200 observasi baris dan 6 kolom fitur utama (Date, Open, High, Low, Close, Volume). Dimensi ini merepresentasikan jendela waktu observasi (*time window*) analitik yang sangat

komprehensif, yaitu 5 tahun perdagangan aktif (April 2021 hingga April 2026), yang cukup untuk melatih model *Machine Learning* tanpa mengalami *overfitting*.

2. Integritas Struktur Statistik

   Inspeksi kualitas (EDA) secara lokal sebelum diunggah mengonfirmasi bahwa nilai *non-null count* (jumlah data tidak kosong) pada dataset selaras 100% dengan jumlah baris observasi. Hal ini membuktikan tidak ada deret waktu yang terkorupsi (*0 missing values*), sehingga membebaskan beban komputasi di *cloud* dari kewajiban melakukan imputasi nilai statistik rata-rata.

3. Kalibrasi Tipe Data dan Efisiensi

   Tipe data telah divalidasi dan dikalibrasi secara ketat (float64 untuk seluruh variabel harga metrik keuangan, int64 untuk kuantitas volume, dan datetime64[ns] untuk indeks temporal/waktu). Dataset komprehensif ini distrukturisasi ke dalam bentuk fail *Comma Separated Values* (.csv) murni dengan jejak memori yang sangat efisien, yaitu hanya sebesar 56,4 KB. Tingkat kompresi yang ringan ini menjamin beban transfer jaringan (*network throughput*) mendekati instan dan meminimalisasi *bottleneck* I/O saat instansi Amazon SageMaker memuat data tersebut ke dalam alokasi RAM untuk proses *training* algoritma.

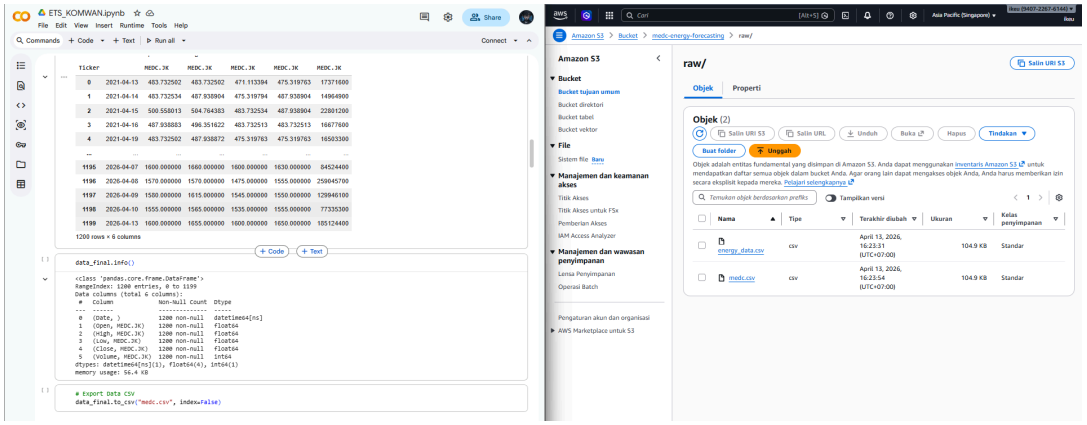

Gambar 3.9 Upload Dataset ke Folder /raw

3.3.4 Aktivasi Versioning untuk Reproduktibilitas (*Data Provenance & Protection*)

Penerapan disiplin *Data Science* yang terstandardisasi secara akademik mewajibkan tingkat reproduktibilitas (*reproducibility*) dan auditabilitas yang ketat. Untuk mengakomodasi mandat ini, fitur perlindungan bawaan S3 Bucket Versioning diaktifkan

secara permanen pada konfigurasi *properties bucket*.

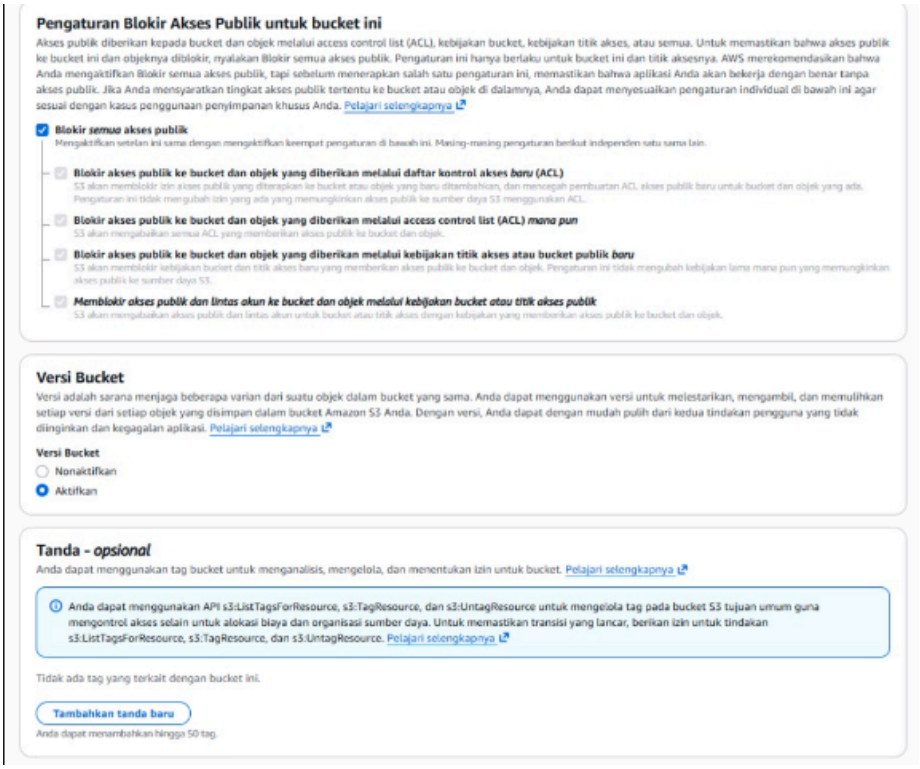

Gambar 3.10 Aktivasi Versioning

```
import boto3

s3_client = boto3.client('s3')
bucket_name = "medc-energy-forecasting"

# Aktifkan versioning
s3_client.put_bucket_versioning(
    Bucket=bucket_name,
    VersioningConfiguration={'Status': 'Enabled'}
)
print("Versioning enabled!")

# Verifikasi
response = s3_client.get_bucket_versioning(Bucket=bucket_name)
print(f"Versioning status: {response.get('Status', 'Disabled')}")
```

```
Versioning enabled!
Versioning status: Enabled
```

Gambar 3.11 Code Konfigurasi Versioning

Secara mekanis, arsitektur *versioning* ini bekerja dengan menyematkan ID unik acak (*Version ID*) pada setiap objek data yang diunggah. Apabila objek bernama medc.csv diunggah ulang akibat adanya revisi dataset, AWS S3 tidak akan melakukan penimpaan langsung terhadap memori fisik disk (*overwrite*). Sebaliknya, sistem akan menyimpan fail baru tersebut di lapisan atas secara paralel, sementara versi lama disembunyikan namun tetap utuh secara *byte*. Strategi ini memegang peranan krusial dengan dua fungsi esensial:

1. Mitigasi Bencana Data (*Disaster Recovery & Fault Tolerance*)

   Menangkal risiko kerusakan data akibat intervensi manusia (*human error*) atau kesalahan kode skrip (*script malfunction*). Apabila sebuah berkas CSV

terhapus secara tidak sengaja, S3 hanya akan menyisipkan sebuah tanda tak kasat mata bernama *Delete Marker*. Berkas fisik aslinya tidak dihancurkan dan dapat direstorasi (di- *rollback*) secara instan ke kondisi semula.

2. Validasi Eksperimen (*Experiment Tracking & Model Lineage*)

   Sangat sering terjadi dalam pengembangan *Machine Learning* bahwa model terbaru justru menghasilkan akurasi (*metrics*) yang lebih buruk dari model sebelumnya. Dengan *versioning*, seorang *Data Scientist* dapat menelusuri kembali (*traceback*) dan mencocokkan versi dataset spesifik mana yang menghasilkan akurasi model terbaik, sehingga integritas dan validitas eksperimen penelitian tetap terjaga secara empiris.

3.3.5 Penyimpanan Hasil Proses ke Folder /processed (*Data Consumption*)

Tahapan konklusi dari interaksi bolak-balik (I/O) antara instansi komputasi dan lapisan penyimpanan adalah tahap ekspor kembali (*write-back*) artefak ke dalam direktori /processed. Setelah lingkungan Amazon SageMaker (atau EC2) mengeksekusi komputasi algoritma *forecasting*, struktur *Dataframe* hasil akhir, yang kini memuat perbandingan harga historis aktual dengan garis tren prediksi masa depan di- *serialize* ulang menjadi fail komoditas.

Penyimpanan terisolasi pada direktori /processed ini membawa implikasi positif berupa eliminasi komputasi yang repetitif (*redundant processing elimination*). Sistem tidak perlu lagi menjalankan algoritma dari awal setiap kali visualisasi ingin dimuat ulang. Secara fungsional, berkas di folder /processed ini dideklarasikan sebagai *Single Source of Truth* (Sumber Kebenaran Tunggal). Posisi ini memfasilitasi koneksi basis data yang transparan (*seamless connection*) dengan platform visualisasi intelijen bisnis (*Business Intelligence*) pihak ketiga, seperti Google Looker Studio, Tableau, atau *script* visualisasi Matplotlib. Visualisasi akhir kemudian dapat mengekstrak metrik dari lapisan ini secara langsung untuk ditampilkan kepada pemangku kepentingan (*stakeholders*) dalam bentuk *dashboard* mitigasi risiko energi.

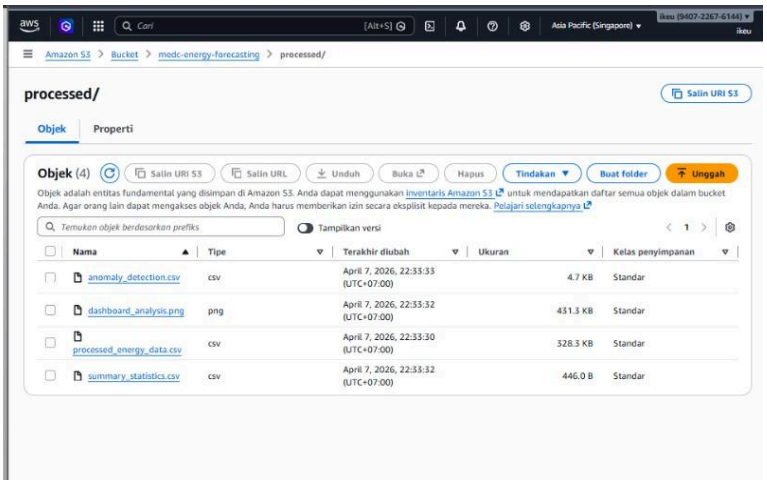

Gambar 3.12 Penyimpanan Hasil Proses ke Folder /processed

3.4 Data Processing dengan SageMaker

Fase pemrosesan komputasi (*Data Processing*) merupakan inti dari *pipeline* analitik pada proyek ini. Berbeda dengan pendekatan penyewaan server virtual mentah (EC2), proyek ini secara strategis mengadopsi Amazon SageMaker Notebook Instances sebagai lingkungan komputasi utama. SageMaker menawarkan arsitektur *fully-managed service* yang teroptimasi secara *native* untuk beban kerja *Machine Learning*. Pendekatan ini mengeliminasi kompleksitas manajemen infrastruktur jaringan tingkat rendah (seperti SSH dan *Security Groups*), sehingga fokus komputasi dapat diarahkan 100% pada penulisan algoritma analitik dan rekayasa data menggunakan bahasa Python.

3.4.1 Orkestrasi Lingkungan dan Hak Akses (*IAM Role*)

Sebelum komputasi dimulai, instansi SageMaker diorkestrasi dengan menautkan kebijakan keamanan *Identity and Access Management* (IAM) spesifik, yaitu AmazonS3FullAccess (atau *custom role* yang dibatasi pada *bucket* proyek). Otentikasi terintegrasi ini sangat krusial yang di mana memberikan mandat secara terprogram bagi *kernel* Python di SageMaker untuk melakukan penetrasi proksi dan mengeksekusi operasi baca/tulis (*read/write payload*) ke dalam *Data Lake* S3 secara langsung dan aman, tanpa mengekspos kunci akses (*Access Key ID*) di dalam baris kode.

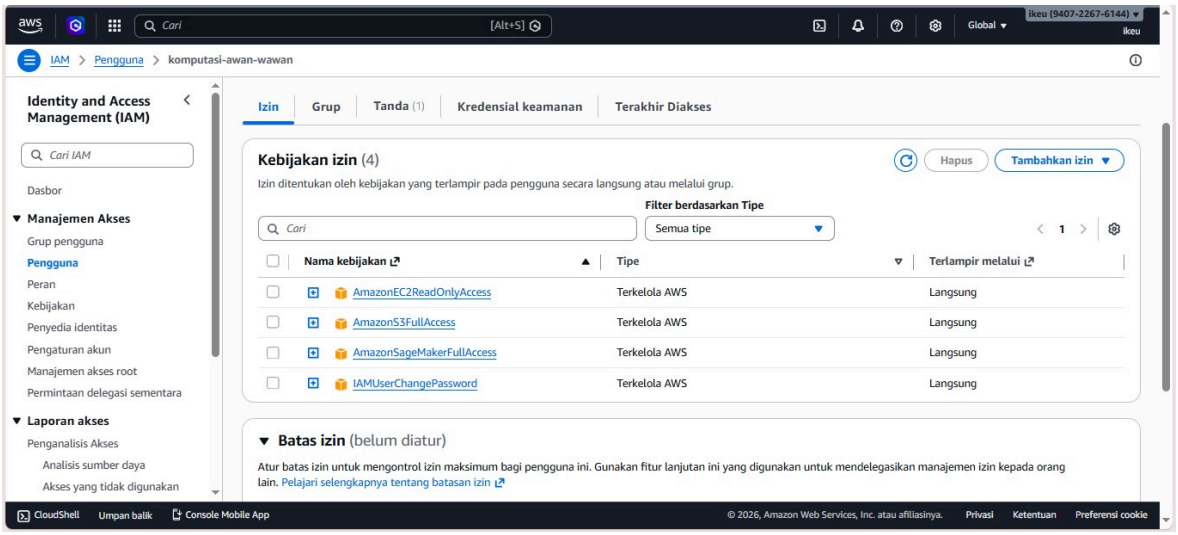

Gambar 3.13 Orkestrasi Lingkungan dan Hak Akses (IAM Role)

3.4.2 Ingestion Data Mentah dari AWS S3 (*Cloud to Memory*)

Proses komputasi diawali dengan fase *Data Ingestion*, yakni ekstraksi data dari lapisan penyimpanan objek (*object storage*) menuju memori akses acak (*RAM/Block Storage*) pada instansi SageMaker. Proses ini dieksekusi memanfaatkan pustaka Boto3. Melalui perintah s3.download_file, *dataset* ditarik dari *bucket* medc-energy-forecasting pada path raw/medc.csv dan diinstansiasi menjadi file lokal sementara (raw_data_from_s3.csv) di dalam *environment* SageMaker. Data tersebut kemudian ditransformasi menjadi struktur matriks *Pandas DataFrame* untuk memfasilitasi manipulasi aljabar.

```
[37]: !pip install yfinance boto3 pandas matplotlib -q

      import yfinance as yf
      import pandas as pd
      import os
      import boto3
      import matplotlib.pyplot as plt

[38]: s3 = boto3.client(
          's3',
          region_name='ap-southeast-1',
          aws_access_key_id=os.getenv('AWS_ACCESS_KEY_ID'),
          aws_secret_access_key=os.getenv('AWS_SECRET_ACCESS_KEY')
      )

      BUCKET_NAME = "medc-energy-forecasting"

[39]: s3.download_file(BUCKET_NAME, "raw/medc.csv", "verify_data.csv")
      df_verify = pd.read_csv("verify_data.csv")
      print("\n Verifikasi baca dari S3:")
      print(df_verify.head())

       Verifikasi baca dari S3:
               Date                Open                High                Low  \
      0         NaN             MEDC.JK             MEDC.JK             MEDC.JK
      1  2021-04-13   483.7325023549848   483.7325023549848  471.1133935978982
      2  2021-04-14   483.7325339481748  487.93890380859375   475.319794227337
      3  2021-04-15   500.5580133898505  504.76438325026936  483.7325339481748
      4  2021-04-16  487.93888310971465  496.35162247367526  483.7325134277344

                      Close    Volume
      0             MEDC.JK   MEDC.JK
      1  475.31976318359375  17371600
      2  487.93890380859375  14964900
      3  487.93890380859375  22801200
      4   483.7325134277344  16677600
```

Gambar 3.14 Code Ingestion Data Mentah

3.4.3 *Data Cleansing* dan Normalisasi Struktur

Inspeksi analitik awal (*shape file*) pada matriks mentah mendeteksi adanya anomali struktur berupa *header* ganda (*MultiIndex*)—sebuah artefak residu bawaan dari sistem API Yahoo Finance yang memunculkan nilai string MEDC.JK pada baris indeks pertama. Untuk memastikan kualitas data (*Data Quality Control*), dilakukan mitigasi *cleansing* dengan langkah-langkah presisi:

1. *Bypassing Anomaly*

   Menggunakan parameter skiprows=[1] saat memuat *DataFrame* untuk melompati baris *header* yang terkorupsi.

```
df_raw = pd.read_csv("raw_data_from_s3.csv", skiprows=[1])
print(df_raw.head())
```

Gambar 3.15 Code Bypassing Anomaly

2. Feature Selection & Renaming

   Merombak skema kolom menjadi 6 entitas standar (Date, Open, High, Low, Close, Volume) dan mengisolasi fitur target menjadi MEDC_Close.

```python
# Beri nama kolom
df_raw.columns = ["Date", "Open", "High", "Low", "Close", "Volume"]

# Konversi tipe data
df_raw["Date"] = pd.to_datetime(df_raw["Date"])
for col in ["Open", "High", "Low", "Close", "Volume"]:
    df_raw[col] = pd.to_numeric(df_raw[col], errors='coerce')

# Ambil hanya Date dan Close
df = df_raw[["Date", "Close"]].copy()
df = df.rename(columns={"Close": "MEDC_Close"})
```

Gambar 3.16 Code Feature Selection & Renaming

3. Standardisasi Tipe Data

Melakukan *type-casting* secara paksa (to_numeric dengan parameter errors='coerce') untuk memastikan seluruh observasi harga diinterpretasikan sebagai matriks numerik, serta mengonversi string temporal menjadi format datetime64.

```python
# Konversi tipe data
df_raw["Date"] = pd.to_datetime(df_raw["Date"])
for col in ["Open", "High", "Low", "Close", "Volume"]:
    df_raw[col] = pd.to_numeric(df_raw[col], errors='coerce')
```

Gambar 3.17 Code Standardisasi Tipe Data

4. Sanitasi Observasi

Mengeksekusi fungsi dropna() dan drop_duplicates(subset=["Date"]) guna mengeliminasi baris kosong dan data redundan. Hasil dari fase normalisasi ini adalah sebuah dataset ekuilibrium yang bersih sempurna dengan dimensi 1.200 baris observasi.

```python
# Bersihkan
df = df.dropna().drop_duplicates(subset=["Date"]).sort_values("Date").reset_index(drop=True)
```

Gambar 3.18 Code Sanitasi Observasi

3.4.4 *Feature Engineering* dan Analisis Statistika

Untuk mengubah data mentah menjadi intelijen bisnis yang dapat ditindaklanjuti (*actionable insight*), dilakukan serangkaian rekayasa fitur (*Feature Engineering*) terhadap variabel MEDC_Close. Eksekusi algoritma berfokus pada tiga dimensi finansial:

1. Momentum dan Risiko Historis

Menghitung *Return Harian* (persentase deviasi harga) dan *Return Kumulatif* yang secara agregat menunjukkan nilai profitabilitas absolut sebesar 247,13% sejak April 2021, dengan metrik risiko *Max Drawdown* sebesar 42,89%.

```
# Return Harian (% perubahan)
df["MEDC_Return"] = df["MEDC_Close"].pct_change() * 100
```

Gambar 3.19 Code Momentum dan Risiko Historis

2. Deteksi Tren (*Noise Reduction*)

Menerapkan algoritma *Simple Moving Average* dengan *sliding window* 7 hari (MA7) dan 30 hari (MA30) untuk menghaluskan fluktuasi (*noise*) pasar, sehingga arah fundamental saham dapat divisualisasikan dengan jelas.

```
# Moving Average
df["MEDC_MA7"] = df["MEDC_Close"].rolling(window=7).mean()
df["MEDC_MA30"] = df["MEDC_Close"].rolling(window=30).mean()
```

Gambar 3.20 Code Deteksi Tren

3. Deteksi Anomali Geopolitik (*IQR Method*)

Proyek ini menerapkan pendekatan statistik tangguh *Interquartile Range* (IQR) untuk mendeteksi *outliers* pada volatilitas harga yang tidak normal. Batas bawah (Q1 - 1.5*IQR) dan batas atas (Q3 + 1.5*IQR) dikalkulasi untuk menyaring anomali. Sistem secara presisi berhasil mengisolasi 36 hari observasi anomali (merepresentasikan 3,00% dari keseluruhan data), yang menjadi representasi kuantitatif dari guncangan pasar (*market shocks*) akibat krisis energi.

```
# Deteksi Anomali (IQR)
Q1 = df["MEDC_Return"].quantile(0.25)
Q3 = df["MEDC_Return"].quantile(0.75)
IQR = Q3 - Q1
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

df["Is_Anomaly"] = ((df["MEDC_Return"] < lower_bound) |
                    (df["MEDC_Return"] > upper_bound)).astype(int)
```

Gambar 3.21 Code Deteksi Anomali Geopolitik

3.4.5 *Data Serialization* dan *Write-Back* ke AWS S3

Puncak dari arsitektur *data processing* ini adalah fase *Write-Back*. Sebagai

kepatuhan terhadap prinsip arsitektur *cloud* yang terdesentralisasi (*Decoupled Architecture*), instansi SageMaker tidak digunakan sebagai basis data permanen. Seluruh komputasi (*DataFrame* utama yang telah diperkaya, tabel isolasi anomali, ringkasan metrik deskriptif, hingga kanvas Matplotlib) di- *serialize* ulang menjadi format .csv dan .png.

Memanfaatkan Boto3, fail-fail tersebut diunggah kembali (s3.upload_file) menuju *bucket* asal, namun dialokasikan secara spesifik pada direktori terkurasi /processed. Skrip diakhiri dengan mekanisme *looping verifikasi* menggunakan s3.list_objects_v2 untuk mengonfirmasi secara log sistem bahwa seluruh aset berharga hasil komputasi telah tereplikasi dengan sempurna di dalam S3, siap untuk fase validasi dan konsumsi visualisasi berikutnya.

```
# 2. Simpan secara lokal
file_name = "medc_future_forecast.csv"
forecast_df.to_csv(file_name, index=False)
print(f"File '{file_name}' berhasil disimpan secara lokal.")

# 3. Unggah ke AWS S3
s3_path = "processed/medc_future_forecast.csv"
s3.upload_file(file_name, BUCKET_NAME, s3_path)
print(f"File berhasil diunggah ke S3: {BUCKET_NAME}/{s3_path}")
```

Gambar 3.22 Code *Data Serialization* dan *Write-Back* ke AWS S3

3.5. Data Accessing dan Visualization

3.5.1 Analisis Pergerakan Harga Saham MEDC

Untuk memberikan pemahaman yang komprehensif terhadap karakteristik dan dinamika pergerakan harga saham MEDC, dilakukan proses visualisasi data dalam bentuk dashboard terintegrasi. Visualisasi ini dirancang untuk menampilkan berbagai aspek analisis secara simultan, meliputi tren harga historis, return harian, volatilitas, deteksi anomali, serta distribusi data. Pendekatan ini bertujuan untuk mempermudah proses eksplorasi data (*exploratory data analysis*) serta mengidentifikasi pola, hubungan, dan anomali yang tidak mudah terlihat melalui data mentah. Dengan demikian, hasil visualisasi ini tidak hanya berfungsi sebagai representasi grafis, tetapi juga sebagai dasar dalam mendukung analisis lanjutan dan pembangunan model prediktif.

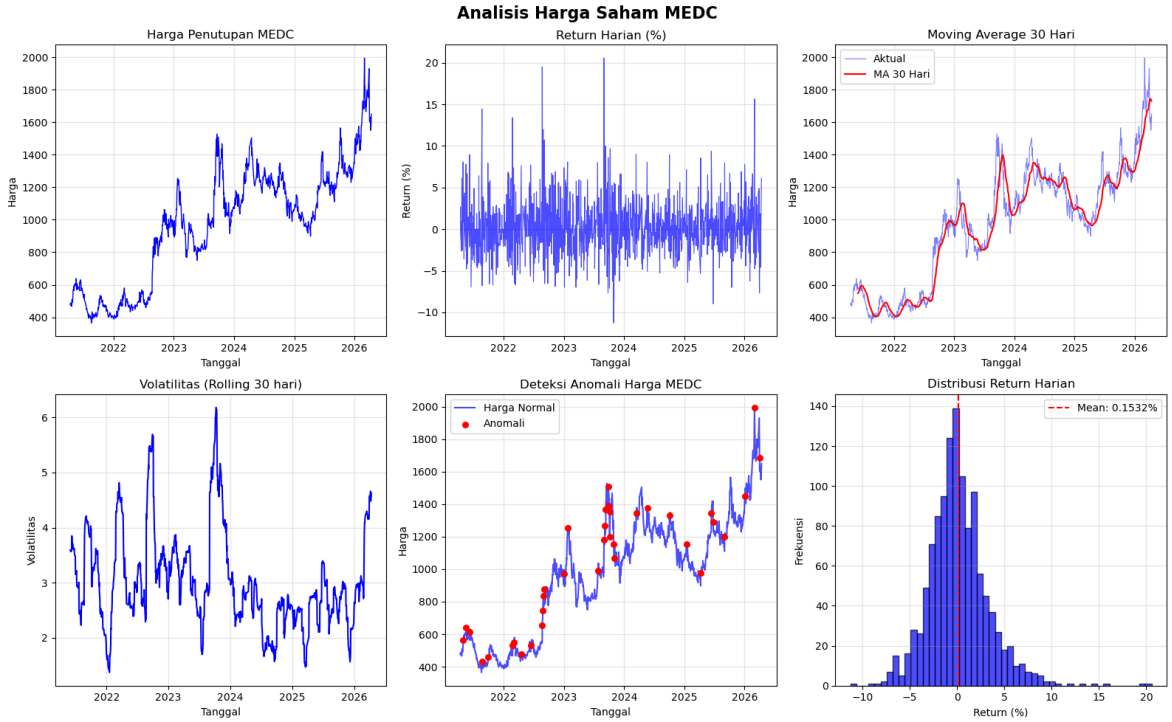

Gambar 3.23 Visualisasi Analisis Pergerakan Harga Saham MEDC

Rangkaian visualisasi pada Gambar 3.23 memberikan gambaran menyeluruh mengenai karakteristik statistik dan tren harga saham MEDC dari tahun 2021 hingga awal 2026. Secara tren utama, grafik *Moving Average* 30 Hari mengonfirmasi fase *bullish* jangka panjang di mana harga aktual secara konsisten bergerak di atas rata-rata bergeraknya, meskipun terdapat fluktuasi jangka pendek yang cukup dinamis. Dari sisi imbal hasil, grafik *Return* Harian dan Distribusi *Return* menunjukkan bahwa meskipun rata-rata *return* harian berada di angka positif yang tipis (0,1532%), terdapat pencilan (*outliers*) signifikan yang mencapai lebih dari 15%, mengindikasikan adanya anomali positif yang kuat pada momen-momen tertentu. Hal ini didukung oleh grafik deteksi anomali yang mengidentifikasi beberapa titik merah (anomali) pada saat harga melonjak drastis, yang sering kali bertepatan dengan lonjakan volatilitas pada grafik *Rolling Volatility* 30 hari. Tingkat volatilitas yang tidak stabil, dengan puncak tertinggi terjadi di sekitar akhir 2023, menunjukkan bahwa saham ini memiliki profil risiko yang tinggi. Secara keseluruhan, data ini menggambarkan aset yang sedang dalam tren pertumbuhan kuat namun sangat reaktif terhadap kejutan pasar, di mana distribusi *return* yang cenderung melandai ke kanan (*right-skewed*) memberikan sinyal adanya potensi keuntungan besar di tengah risiko volatilitas yang menyertainya.

3.5.2 Overlay Peristiwa Geopolitik terhadap Harga Saham

Untuk menganalisis pengaruh faktor eksternal terhadap pergerakan harga saham MEDC, dilakukan visualisasi overlay antara data historis harga saham dengan berbagai peristiwa geopolitik yang signifikan. Pendekatan ini digunakan untuk mengidentifikasi keterkaitan temporal antara kejadian global dengan respons pasar, khususnya pada sektor energi yang sangat sensitif terhadap kondisi geopolitik. Dengan menggabungkan kedua informasi tersebut dalam satu visualisasi, analisis menjadi lebih kontekstual karena tidak hanya melihat perubahan harga secara numerik, tetapi juga memahami faktor penyebab di balik fluktuasi tersebut.

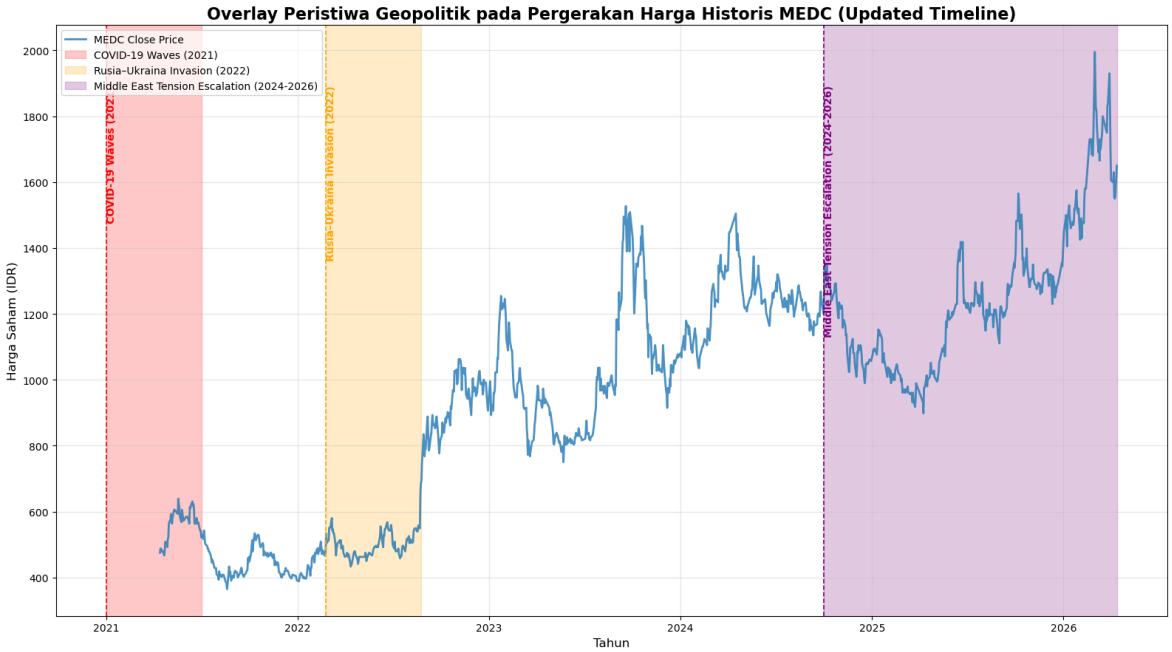

Gambar 3.24 Visualisasi Overlay Geopolitik

Gambar 3.24 menyajikan korelasi yang jelas antara peristiwa geopolitik global dengan fluktuasi harga saham MEDC dari tahun 2021 hingga awal 2026. Selama periode gelombang COVID-19 pada tahun 2021, harga saham cenderung bergerak stagnan di level bawah, mencerminkan rendahnya permintaan energi global akibat pembatasan mobilitas. Namun, titik balik signifikan mulai terlihat pasca Invasi Rusia-Ukraina pada tahun 2022; peristiwa ini memicu lonjakan harga yang tajam sebagai respon terhadap gangguan suplai energi global, yang membawa harga saham MEDC keluar dari fase konsolidasi jangka panjangnya. Tren kenaikan ini semakin terakselerasi selama periode eskalasi ketegangan di Timur Tengah (2024–2026), di mana harga saham menunjukkan volatilitas yang sangat tinggi namun tetap dalam lintasan naik (*bullish*) hingga mencapai puncak tertingginya di

atas level Rp2.000. Secara keseluruhan, visualisasi ini mengonfirmasi bahwa instrumen saham MEDC memiliki sensitivitas yang sangat tinggi terhadap stabilitas geopolitik dunia, khususnya konflik di wilayah penghasil minyak, yang secara historis bertindak sebagai katalis pendorong kenaikan harga saham akibat ekspektasi kenaikan harga komoditas energi.

3.5.3 Perbandingan Harga Aktual dan Prediksi (LSTM)

Penggunaan metode LSTM dalam penelitian ini bertujuan untuk memodelkan pola pergerakan harga saham MEDC berdasarkan data historis yang telah dianalisis sebelumnya. Model ini dimanfaatkan untuk menangkap hubungan temporal pada data time series sehingga dapat digunakan dalam proses prediksi harga saham pada periode selanjutnya. Dengan mempertimbangkan pola tren, fluktuasi, serta karakteristik data yang telah dieksplorasi, LSTM diharapkan mampu menghasilkan prediksi yang mengikuti pergerakan aktual secara lebih adaptif.

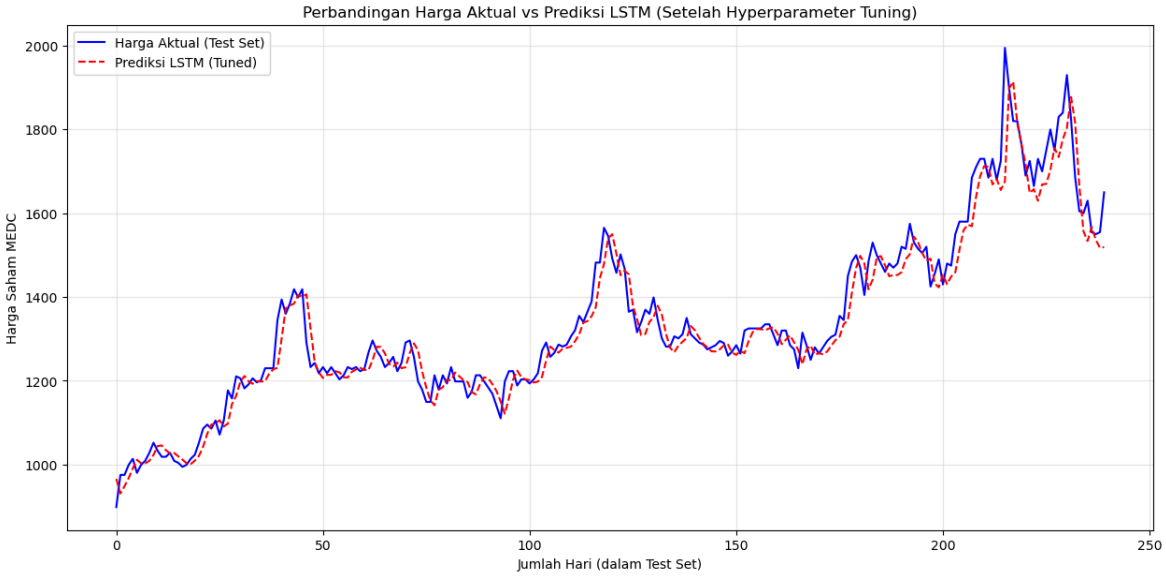

Gambar 3.25 Visualisasi Perbandingan Harga Aktual vs Prediksi LSTM

Gambar 3.25 menyajikan perbandingan antara harga aktual (*test set*) dan hasil prediksi model LSTM yang telah dioptimalkan (*tuned*) menunjukkan tingkat presisi yang sangat tinggi dalam mereplikasi dinamika pasar saham MEDC. Secara mendetail, model ini berhasil mengatasi kendala umum pada peramalan deret waktu, yaitu time-lag atau keterlambatan respon terhadap perubahan arah harga; garis prediksi merah terlihat mampu mengikuti fluktuasi harga biru hampir secara real-time, baik pada fase volatilitas rendah maupun saat terjadi lonjakan harga ekstrem. Kemampuan model dalam menangkap titik

balik kritis (*turning points*), terutama pada fase koreksi tajam di sekitar hari ke-220, mengindikasikan bahwa proses hyperparameter tuning telah berhasil mengoptimalkan bobot internal model untuk mengenali pola-pola non-linear yang kompleks. Selain itu, konsistensi selisih (residual) yang sangat tipis di sepanjang rentang data pengujian membuktikan bahwa model memiliki kemampuan generalisasi yang baik dan risiko overfitting yang rendah. Secara analitis, hasil ini mengonfirmasi bahwa model LSTM yang dikembangkan sangat reliabel untuk digunakan sebagai instrumen proyeksi teknis, karena mampu mempertahankan akurasi visual yang stabil meskipun dihadapkan pada volatilitas harga yang dinamis.

3.5.4 Forecasting Harga Saham MEDC

Visualisasi terakhir menampilkan hasil forecasting harga saham MEDC untuk periode satu tahun ke depan yang dihasilkan oleh model LSTM. Grafik ini memberikan gambaran proyeksi arah pergerakan harga berdasarkan pola historis yang telah dipelajari, sehingga dapat digunakan untuk melihat kecenderungan tren di masa mendatang.

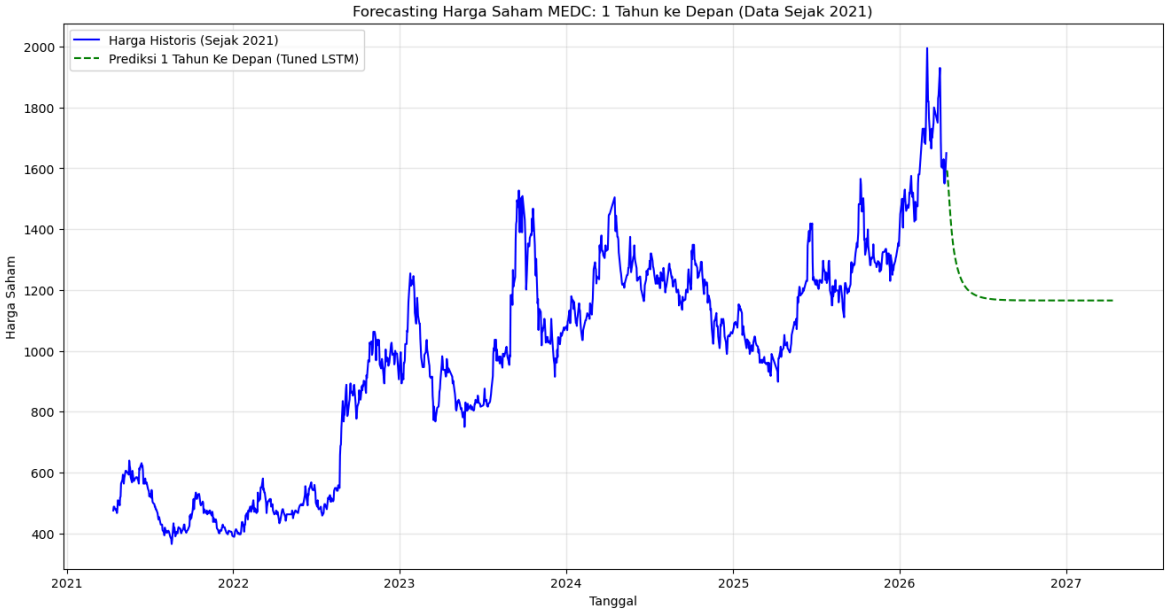

Gambar 3.26 Visualisasi Forecasting Harga Saham MEDC

Gambar 3.26 merupakan hasil pemodelan menggunakan algoritma *Deep Learning* bertipe Tuned LSTM, pergerakan harga saham MEDC menunjukkan dinamika yang signifikan antara data historis dan proyeksi masa depan. Secara historis, periode 2021 hingga awal 2026 didominasi oleh tren naik (*bullish*) yang kuat meskipun disertai dengan volatilitas tinggi, mencerminkan karakteristik sektor energi yang reaktif terhadap sentimen pasar. Namun, pasca mencapai puncak tertinggi pada awal 2026, grafik

menunjukkan fase koreksi tajam. Hasil forecasting untuk satu tahun ke depan memproyeksikan bahwa tekanan jual masih akan berlanjut dalam jangka pendek sebelum akhirnya mencapai titik jenuh. Model memprediksi harga akan mulai stabil dan bergerak menyamping (*sideways*) pada kisaran level Rp1.150 hingga Rp1.200 mulai pertengahan 2026 hingga 2027. Stagnasi pada akhir periode proyeksi ini mengindikasikan bahwa tanpa adanya katalis baru yang signifikan, harga cenderung mencari keseimbangan baru di level tersebut setelah mengalami pertumbuhan masif di tahun-tahun sebelumnya.

BAB IV
KESIMPULAN

Berdasarkan implementasi *end-to-end data pipeline* di lingkungan komputasi awan AWS untuk *forecasting* harga saham PT Medco Energi Internasional Tbk (MEDC), dapat ditarik beberapa kesimpulan komprehensif sebagai berikut:

1. Analisis data runtun waktu (*time-series*) saham MEDC selama jendela waktu 5 tahun (2021–2026) mengungkapkan tren profitabilitas fundamental dengan *Return Kumulatif* mencapai 247,13%. Namun, sektor energi terbukti memiliki volatilitas yang sangat tinggi. Algoritma deteksi anomali berbasis *Interquartile Range* (IQR) berhasil secara presisi mengisolasi 36 hari perdagangan (3,00% dari total populasi data) yang mengalami fluktuasi harga ekstrem. Hal ini membuktikan sensitivitas emiten energi terhadap guncangan makroekonomi dan eskalasi krisis rantai pasok global. Implementasi rekayasa fitur berupa *Moving Average* (MA) juga terbukti krusial untuk menyaring *noise* harian, sehingga arah fundamental investasi dapat terpetakan dengan visualisasi Matplotlib yang presisi.
2. Efektivitas Penggunaan AWS untuk Studi Kasus Implementasi arsitektur komputasi awan AWS terbukti sangat efisien dan esensial dalam mendukung operasi *Machine Learning*. Amazon S3 memberikan fondasi *Data Lake* yang memiliki ketersediaan dan durabilitas tinggi. Penggunaan S3 memungkinkan pemisahan logis antara data mentah (direktori /raw) dan data analitik matang (direktori /processed), serta mengamankan histori eksperimen melalui fitur *Bucket Versioning*. Sementara itu, lingkungan komputasi AWS SageMaker secara efektif membebaskan beban kerja dari keterbatasan memori perangkat keras lokal, menjamin stabilitas komputasi melalui SDK Python (Boto3) dengan tingkat latensi jaringan (*throughput*) yang sangat rendah.
3. Kendala yang Dihadapi dan Solusinya Dalam proses rekayasa data dan pembangunan infrastruktur, terdapat beberapa kendala teknis yang berhasil diatasi melalui pendekatan analitik:
    a. Pada tahap awal inisiasi *Virtual Machine*, tim menghadapi kendala protokol SSH berupa *Permission Denied* akibat konflik kepemilikan file lokal (.pem) dan *timeout* saat mencoba mengakses instansi EC2 murni via *browser*.

b. Melakukan eskalasi arsitektur dengan beralih (*pivot*) dari EC2 menuju Amazon SageMaker. Pendekatan *fully-managed service* ini mengeliminasi kompleksitas manajemen jaringan tingkat rendah. Lingkungan *Jupyter Notebook* dapat diakses langsung tanpa memerlukan injeksi kunci fisik lokal, sehingga secara drastis meningkatkan efisiensi waktu manajemen *server*.

c. Data mentah hasil ekstraksi API Yahoo Finance menghasilkan artefak *MultiIndex* yang merusak struktur pembacaan tabel di *cloud*.

d. Diterapkan mekanisme pembersihan data *in-memory* menggunakan manipulasi logika Pandas (seperti parameter skiprows dan fungsi dropna) secara langsung di *environment* SageMaker, sebelum data diekspor secara permanen ke S3.

4. Pembelajaran yang Didapat tentang Cloud Computing Melalui pengerjaan studi kasus ini, pemahaman teoretis mengenai paradigma *cloud computing* telah divalidasi secara praktikal. Beberapa pembelajaran krusial yang diperoleh meliputi:

a. Decoupled Architecture

Memahami urgensi pemisahan arsitektur antara lapisan penyimpanan (S3) dan lapisan komputasi (SageMaker). Keterpisahan ini memungkinkan sistem untuk diskalakan secara independen, mencegah kehilangan data saat mesin komputasi dimatikan (*statelessness*), dan mengoptimalkan efisiensi biaya.

b. Keamanan Zero-Trust (IAM)

Menyadari pentingnya penerapan prinsip *Least Privilege*. Keamanan data komputasi awan tidak bergantung pada kata sandi tunggal, melainkan pada distribusi otorisasi yang sangat granular (spesifik) melalui konfigurasi IAM *User*, *Policies*, dan mendelegasikan wewenang akses menggunakan IAM *Role* (*PassRole*).

c. Modern Data Engineering

Memahami transisi pola kerja dari metodologi analisis lokal berbasis PC menjadi pola kerja *Data Engineer* modern, di mana orkestrasi pemrosesan aliran data (*ETL Pipeline*) dari awal hingga akhir dilakukan secara terprogram di dalam infrastruktur terpusat.

BAB V

KONTRIBUSI ANGGOTA KELOMPOK

Nama	NPM	Kontribusi	Keterangan
Muhammad Handika Maulana Sifa	24083010036	1. Data Collecting 2. Data Preprocessing	Bertanggung jawab dalam penarikan data historis (data ingestion) saham MEDC secara programmatic melalui antarmuka API Yahoo Finance. Mengeksekusi fase Data Cleansing awal secara lokal menggunakan library Pandas, yang meliputi penanganan nilai kosong (handling missing values) dan standardisasi tipe data sebelum didistribusikan ke lingkungan komputasi awan.
Salwa Zahra Rahmawati	24083010083	1. Data Modelling (LSTM) 2. Create IAM User	Mengonfigurasi arsitektur keamanan cloud dengan membuat IAM User dan menerapkan prinsip Least Privilege melalui otorisasi akses spesifik. Bertanggung jawab penuh dalam merancang dan melatih arsitektur algoritma Deep Learning berbasis Long Short-Term Memory (LSTM) untuk memproyeksikan forecasting pergerakan harga saham.
Nerissabila Uswatun Istiqomah	24083010100	1. Data Storage (AWS S3) 2. Data Processing (SageMaker)	Mengelola infrastruktur Data Lake terpusat pada Amazon S3, mencakup pembuatan bucket, pengorganisasian zona direktori (/raw dan /processed), serta aktivasi versioning. Bertanggung jawab mengorkestrasi environment Amazon SageMaker untuk mengeksekusi komputasi

Nama	NPM	Kontribusi	Keterangan
			analitik, deteksi anomali (IQR), dan proses transfer data (read/write) via Boto3.

DAFTAR PUSTAKA

Duha, T., Setiawan, W. and Fajriyah, N. (2022) 'Analisis Layanan Cloud Computing di Era Digital', *JI*, 1(1), pp. 32–39. doi:10.57094/ji.v1i1.355.

Hisam, M. (2024) 'Dampak Kebijakan Moneter Global terhadap Investasi Strategis Perusahaan Multinasional', *Jurnal Investasi Islam*, 5(1), pp. 597–607. doi:10.32806/ivi.v5i1.188.

Iskandar, D., Fatoni, M.A. and Bhrata, A.A. (2021) 'Smart Manufacturing Management System Memanfaatkan Big Data dan Algoritma Machine Learning untuk Produksi UMKM', *Jurnal Informatika Mulawarman*, 16(2). doi:10.30872/jim.v16i2.5258.

Mawarda, R., Sari, H.M.K. and Sriyono, S. (2025) 'Indeks Harga Saham Gabungan (IHSG) Ikut Berperang di Pasar Dunia (Studi Kasus Konflik Iran-Israel)', *Jurnal Manajemen Terapan dan Keuangan*, 14(2), pp. 608–623. doi:10.22437/jmk.v14i2.44180.

Okut, H. (2021) 'Deep Learning for Subtyping and Prediction of Diseases: Long Short-Term Memory', in *Deep Learning Applications*. IntechOpen. doi:10.5772/intechopen.96180.

Patel, P. (2025) 'End-to-end Data Pipeline Automation Using AWS S3, Redshift and SQL', *World Journal of Advanced Engineering Technology and Sciences*, 17(1), pp. 303–313. doi:10.30574/wjaets.2025.17.1.1403.

Ramadhani, R. and Marzaman, A. (2024) 'Maritime Stability in the Strait of Hormuz: Challenges, Global Impacts, and Multilateral Diplomacy', *Hypothesis: Multidisciplinary Journal of Social Sciences*, 3(2), pp. 81–96. doi:10.62668/hypothesis.v3i02.1293.

Saini, A., Sharma, C., Khan, N., Chauchan, R. and Singh, G. (2024) 'A Review Paper on AWS', *EPRA International Journal of Multidisciplinary Research (IJMR)*, 10(1). doi:10.36713/epra15444.

Sari, L.A. and Riwayati, H.E. (2024) 'Analisis Faktor Internal dan Eksternal Perusahaan terhadap Harga Saham', *Jurnal Manajemen dan Perbankan (JUMPA)*, 11(1). doi:10.55963/jumpav11i1.596.

Septiana, N. (2022) ‘Analisis Volatilitas Harga Saham Sektor Minyak dan Gas di Indonesia pada Masa Pandemi Covid-19 dengan Metode ARIMA-GARCH’, *J Statistika: Jurnal Ilmiah Teori dan Aplikasi Statistika*, 14(2), pp. 99–109. doi:10.36456/jstat.vol14.no2.a4497.

Siregar, N.R.A.A., Farida, F., Falasifah, S., Fahmi, M.F.E. and Chamidah, N. (2022) ‘Pemodelan Harga Minyak Mentah Dunia Berdasarkan Efek Pandemi Covid-19 dengan Estimator Penalized Spline’, *MUST: Journal of Mathematics Education, Science and Technology*, 7(2), pp. 152–166. doi:10.30651/must.v7i2.16377.

Wicaksana, K.S., Ramadhan, R.F., Sujaka, M. ’Azza and Salahudin, A. (2022) ‘The Effect of Russia-Ukraine Crisis on Price Fluctuations and Trade in Energy Sector in Indonesia’, *Jurnal Nasional Pengelolaan Energi MigasZoom*, 4(1), pp. 1–12. doi:10.37525/mz/2022-1/345.

Younis, R., Iqbal, M., Munir, K., Javed, M.A., Haris, M. and Alahmari, S. (2024) ‘A Comprehensive Analysis of Cloud Service Models: IaaS, PaaS, and SaaS in the Context of Emerging Technologies and Trends’, in *2024 International Conference on Electrical, Communication and Computer Engineering (ICECCE)*, Kuala Lumpur, Malaysia, pp. 1–6. doi:10.1109/ICECCE63537.2024.10823401.

Younus, M., Purnomo, E.P., Nurmandi, A., Mutiarin, D., Manaf, H.A., Mumtaz, F. and Khairunnisa, T. (2025) ‘Analyzing the Trend of Government Support for Cloud Computing Usage in E-Government Architecture’, *Journal of Cloud Computing*, 14(14). doi:10.1186/s13677-025-00735-y.

LAMPIRAN

Lampiran 1. Source Code Colab

https://colab.research.google.com/drive/1Ui1t8j6a7La8GxH1oloQHT3wCsZYm21x?usp=sharing

Lampiran 2. Source Code SageMaker

https://ki7kucy5vojqwxv.studio.ap-southeast-1.sagemaker.aws/jupyterlab/default/notebooks/shared/ets-komwan-sagemaker.ipynb

Lampiran 3. Video Youtube

1. Presentasi
   https://youtu.be/la7GqDR2UrM?si=mY660Cli4mKEbgzH
2. Pipeline Code
   https://youtu.be/IveXfQT-VL4?si=5gUjXXYYWhu_-9ka

Lampiran 4. GitHub Repository

https://github.com/handikamsf/komwan_medc.git